



PHÂN TÍCH DỮ LIỆU



TIỀN XỬ LÝ DỮ LIỆU


1. Giới thiệu tiền xử lý dữ liệu
2. Công việc trong tiền xử lý dữ liệu
3. Làm sạch dữ liệu
4. Các cách làm sạch dữ liệu
5. Tổng hợp và biến đổi dữ liệu

1 Giới thiệu tiền xử lý dữ liệu

Data Pre-Processing: là kỹ thuật khai phá dữ liệu để biến đổi dữ liệu thô thành những dạng dữ liệu có thể phân tích được.

Data wrangling: là quá trình tập hợp, lựa chọn và chuyển đổi thành những dữ liệu thích hợp cho việc phân tích dữ liệu.

Tiền xử lý dữ liệu còn được gọi là data munging. Có nhiều ý kiến cho rằng quá trình này chiếm đến 80% công việc của người phân tích dữ liệu. 20% còn lại là việc khám phá và mô hình hóa.







Data Pre-Processing: là kỹ thuật được dùng để chuyển đổi dữ liệu thô thành dữ liệu sạch.

Data wrangling: là một kỹ thuật được thực hiện tại thời điểm tạo mô hình. Nói cách khác, nó được sử dụng để chuyển đổi dữ liệu thô sang định dạng thuận tiện cho việc sử dụng, phân tích dữ liệu.

1 Giới thiệu tiền xử lý dữ liệu



1 Giới thiệu tiền xử lý dữ liệu



What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

1 Giới thiệu tiền xử lý dữ liệu

Tại sao phải cần tiền xử lý dữ liệu

Đối với các thuật toán trong mô hình học máy, chất lượng của dữ liệu là quan trọng nhất. Hiệu suất làm việc hoặc độ chính xác phụ thuộc rất nhiều vào dữ liệu huấn luyện này.

Chất lượng của dữ liệu

- Độ chính xác: đúng hay sai, chính xác hay không chính xác.
- Tính đầy đủ: có thiếu dòng, thiếu cột, thiếu giá trị.
- Tính nhất quán: các giá trị trong cùng 1 cột có giống nhau.
- Tính kịp thời: dữ liệu có mới, có được update không.
- Độ tin cậy: dữ liệu có đáng tin cậy hay không.
- Khả năng diễn giải: dữ liệu có dễ hiểu hay không.

1 Giới thiệu tiền xử lý dữ liệu



Tại sao phải cần tiền xử lý dữ liệu

Dữ liệu trong thực tế là dữ liệu không “sạch”

- Incomplete: thiếu giá trị, thiếu thuộc tính... Ví dụ: lương = “ “
- Noisy: giá trị bị sai. Ví dụ: chiều cao = -150 cm
- Inconsistent: có sự khác biệt về dữ liệu trong cùng 1 thuộc tính

Ví dụ: Age = 43, birthday = “03/07/1997”

Đánh giá “1,2,3” hoặc “Good, not good, bad”

e.g.,: Discrepancy between duplicate records.

- Duplicate: dữ liệu bị trùng lặp

Giới thiệu tiền xử lý dữ liệu

Tại sao dữ liệu lại có những vấn đề này?

- Dữ liệu không đầy đủ có thể ở nguyên nhân:
 - N/A (Not applicable) dữ liệu không được thu thập.
 - Lỗi do người gây ra
 - Lỗi do thiết bị phần cứng hoặc phần mềm.
- Dữ liệu nhiễu (giá trị bị sai) có từ nguyên nhân:
 - Công cụ thu thập dữ liệu bị lỗi.
 - Lỗi của người hoặc máy khi nhập dữ liệu.
 - Lỗi do truyền dữ liệu
- Dữ liệu không nhất quán có thể từ nguyên nhân:
 - Từ nhiều nguồn dữ liệu khác nhau.
 - Từ nhiều định dạng khác nhau.
- Dữ liệu bị trùng lặp.

1 Giới thiệu tiền xử lý dữ liệu

Tại sao tiền xử lý dữ liệu là công việc quan trọng?

- Hầu hết dữ liệu thu thập được là dữ liệu không hoàn chỉnh, không “sạch”.
- Chất lượng của dữ liệu là yếu tố quan trọng cho quá trình phân tích, xây dựng mô hình.
- Thuật ngữ Garbage in, Garbage Out (GIGO)
- Dữ liệu không chất lượng thì kết quả không tốt
 - Quyết định chất lượng phải dựa trên dữ liệu có chất lượng.
 - Dữ liệu trùng, thiếu có thể gây ra thống kê không chính xác hoặc sai lệch.
 - Ảnh hưởng đến việc lưu trữ dữ liệu trong data warehouse.




2 Công việc trong tiền xử lý dữ liệu



Các công việc chính của tiền xử lý dữ liệu

Data Cleaning: Dữ liệu có thể có những phần không liên quan, những giá trị bị thiếu, hoặc bị sai sót. Có nhiều cách để xử lý loại dữ liệu không sạch này: điền giá trị, loại bỏ dòng, cột (thuộc tính)

Data Integration: Tổng hợp dữ liệu từ nhiều nguồn khác nhau như: database, tập tin, online, offline.




2 Công việc trong tiền xử lý dữ liệu




Data Transformation: Chuẩn hóa và chuyển đổi dữ liệu.

Data Reduction hoặc Dimension Reduction: giảm số lượng thuộc tính của dữ liệu.


Data discretization: rời rạc hóa dữ liệu sẽ làm giảm đi các trường hợp của dữ liệu.



2 Công việc trong tiền xử lý dữ liệu



Data transformation $-2, 32, 100, 59, 48 \longrightarrow -0.02, 0.32, 1.00, 0.59, 0.48$




2 Công việc trong tiền xử lý dữ liệu



Ví dụ về tổng hợp dữ liệu

Customers data

	A	B	C	D	E	F	G	H
1	id	firstname	lastname	age	city			
2	1	Noah	SMITH	34	San Francisco			
3	2	Emma	JOHNSON	19	New York			
4	3	Liam	WILLIAMS	45	Chicago			
5	4	Olivia	JONES	18	Jersey City			
6	5	William	BROWN	85	Seattle			
7	6	Ava	DAVIS	55	Orlando			
8	7	Mason	MILLER	58	Los Angeles			
9	8	Sophia	WILSON	35	Columbus			
10	9	James	MOORE	31	San Francisco			
11	10	Isabella	TAYLOR	38	Columbus			
12	11	Benjamin	ANDERSON	26	San Francisco			
13	12	Mia	THOMAS	72	Raleigh			
14	13	Jacob	JACKSON	91	Memphis			



2 Công việc trong tiền xử lý dữ liệu



Ví dụ về rời rạc hóa dữ liệu

Divorced	Handlers-cleaners	Not-in-family	White	Male	0	0	40	United-States	<=50K
Married-civ-spouse	Handlers-cleaners	Husband	Black	Male	0	0	40	United-States	<=50K
Married-civ-spouse	Prof-specialty	Wife	Black	Female	0	0	40	Cuba	<=50K
Married-civ-spouse	Exec-managerial	Wife	White	Female	0	0	40	United-States	<=50K
Married-spouse-absent	Other-service	Not-in-family	Black	Female	0	0	16	Jamaica	<=50K
Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	45	United-States	>50K
Never-married	Prof-specialty	Not-in-family	White	Female	14084	0	50	United-States	>50K

3 Làm sạch dữ liệu



Data Cleaning: là quá trình hiệu chỉnh hoặc loại bỏ những dữ liệu không chính xác, sai định dạng, trùng lặp, không liên quan, không đầy đủ hoặc sai sót trong dữ liệu.

Một số công việc làm sạch dữ liệu:

- Điền vào các giá trị bị thiếu.
- Xác định giá trị biên và làm mịn dữ liệu nhiễu.
- Sửa những dữ liệu không nhất quán
- Giải quyết dữ liệu dư thừa.



3 Làm sạch dữ liệu

Ví dụ 1

	educ	marit	start	jtype	whours	salary
1	.	2	07-May-2016	1	28.25	\$1,6
2	4	1	27-Oct-2026	1	.	\$1,7
3	5			1	22.75	\$1,5
4	1			.	27.25	\$1,9
5	3			1	.	\$1,3
6	6	2	08-Dec-2016	2	43.75	\$3.5

System missing values
are indicated by dots.

Ví dụ 2

PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	male	22	1	0	A/5 21171	7.25		S
2	1	1	female	38	1	0	PC 17599	71.2833	C85	C
3	1	3	female	26	0	0	STON/O2. 3101282	7.925		S
4	1	1	female	35	1	0	113803	53.1	C123	S
5	0	3	male	35	0	0	373450	8.05		S
6	0	3	male		0	0	330877	8.4583		Q



Xử lý dữ liệu thiếu (missing data)

- **Bỏ qua giá trị bị thiếu:** Loại bỏ những dòng có giá trị bị thiếu.
Lưu ý: Việc loại bỏ này chỉ nên thực hiện với bộ dữ liệu nhiều và không ảnh hưởng nhiều đến dữ liệu.
- **Điền vào các giá trị bị thiếu** một cách thủ công
- **Điền vào các giá trị bị thiếu:**
 - Giá trị: trung bình, xuất hiện nhiều nhất, trung vị...
 - Giá trị được dự đoán: Bayesian, Decision tree, Regression



Sử dụng giá trị mean

	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	NaN
1	9	NaN	9.0	0	7.0
2	19	17.0	NaN	9	NaN

mean()



	col1	col2	col3	col4	col5
0	2.0	5.0	3.0	6.0	7.0
1	9.0	11.0	9.0	0.0	7.0
2	19.0	17.0	6.0	9.0	7.0

Sử dụng giá trị 0


	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	NaN
1	9	NaN	9.0	0	7.0
2	19	17.0	NaN	9	NaN

df.fillna(0)




	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	0.0
1	9	0.0	9.0	0	7.0
2	19	17.0	0.0	9	0.0

- Dữ liệu nhiễu (noise): Dữ liệu nhiễu là dữ liệu vô nghĩa mà máy không thể giải thích được.
- Dữ liệu nhiễu có thể được tạo ra do thu thập dữ liệu bị lỗi, lỗi nhập liệu, lỗi ngẫu nhiên hoặc sai số của biến đo, của máy tính.
- Một vài vấn đề trong dữ liệu nhiễu cần được làm sạch
 - Dữ liệu trùng lặp.
 - Dữ liệu chưa hoàn thiện.
 - Dữ liệu không nhất quán.





Xử lý dữ liệu nhiễu



Có 4 phương pháp xử lý dữ liệu nhiễu

1. **Binning**: Chia dữ liệu thành các khoảng
2. **Regression**: Sử dụng mô hình regression để dự đoán giá trị.
3. **Clustering**: Phát hiện và loại bỏ dữ liệu ngoại lai (outliers).
4. **Kết hợp giữa máy và con người**: Sử dụng các phương pháp trên sau đó kiểm tra lại bằng con người.


Phương pháp Binning

Phân chia theo khoảng cách:

- Chia thành các dãy bằng nhau.
- Giá trị được chuyển đổi $W = (B-A)/N$. A, B là số nhỏ nhất và lớn nhất trong từng dãy số.

Phân chia theo Equal-depth (tần suất):

- Chia dãy thành N khoảng, mỗi khoảng có chứa số lượng các máy gần bằng nhau.
- Lấy giá trị trung bình hoặc giá trị biên.



Ví dụ về phương pháp binning

- * Sorted data for price (in dollars): 4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34
- * Partition into (equi-depth) bins:
 - Bin 1: 4, 8, 9, 15
 - Bin 2: 21, 21, 24, 25
 - Bin 3: 26, 28, 29, 34
- * Smoothing by bin means:
 - Bin 1: 9, 9, 9, 9
 - Bin 2: 23, 23, 23, 23
 - Bin 3: 29, 29, 29, 29
- * Smoothing by bin boundaries:
 - Bin 1: 4, 4, 4, 15
 - Bin 2: 21, 21, 25, 25
 - Bin 3: 26, 26, 26, 34

Phương pháp này cũng có thể dùng để rời rạc hóa dữ liệu

3 Làm sạch dữ liệu

Ví dụ về binning

Ví dụ 1

AGE	AGE_bins
10	[10, 16]
15	[10, 16]
16	[10, 16]
18	[17, 30]
20	[17, 30]
30	[17, 30]
35	[31, 48]
42	[31, 48]
48	[31, 48]
50	[49, 55]
52	[49, 55]
55	[49, 55]

Ví dụ 2


Base Data				Binned Data			
ID	Name	Salary	Location	ID	From	To	Location
1	Ram	25000	IN	1	0	25000	6
2	Joe	30000	UK	2	25001	30000	4
3	Siva	22000	IN	3	30001	35000	2
4	Ria	31000	AU	4	35001	99999	1
5	Ben	12000	US				
6	Mary	21000	US				
7	Ali	24000	UK				
8	Jack	45000	CA				
9	Daniel	35000	US				
10	John	22000	IN				
11	Walker	29000	US				
12	Jim	30000	UK				
13	Beam	27500	CA				

ID	From	To	Location
1	0	25000	6
2	25001	50000	7
3	50001	99999	0

3 Làm sạch dữ liệu




Phương pháp Regression




Phân cụm hoặc phân tích giá trị ngoại lai


- Phân cụm: Tạo ra các group có giá trị tương tự nhau. Các giá trị không nằm trong các cụm thì loại bỏ, hoặc thay thế bằng một giá trị nào đó.
- Phân tích ngoại lai:



Kết hợp giữa máy và con người

1. Sử dụng các phương pháp để xử lý
2. Kiểm tra lại thủ công






- Data Integration: là quá trình kết hợp dữ liệu từ nhiều nguồn khác nhau thành một dữ liệu duy nhất.
- Tổng hợp dữ liệu bắt đầu bằng việc đưa dữ liệu vào, làm sạch dữ liệu và chuyển đổi dữ liệu.
- Tổng hợp dữ liệu là một trong những bước của quá trình tiền xử lý dữ liệu.




Một vài vấn đề trong quá trình tổng hợp dữ liệu

- Đối tượng: Các đối tượng giống nhưng có thể được viết dưới những tên gọi khác nhau.
- Các hệ số đo lường khác nhau của các quốc gia, vùng miền.
- Các thuộc tính dư thừa:
 - Là các thuộc tính giống nhau.
 - Có thể phát hiện bằng tương quan nhau.
 - Loại bỏ thuộc tính dư thừa giúp: giảm chiều, tăng chất lượng dữ liệu, cải thiện hiệu năng.




- **Hệ số tương quan (Correlation coefficient)** là chỉ số thống kê đo lường mức độ mạnh yếu của mối quan hệ giữa hai biến số. *Hệ số tương quan có giá trị từ -1 đến 1.*
- - Hệ số tương quan có giá trị âm cho thấy hai biến có mối quan hệ nghịch biến hoặc tương quan âm (nghĩa là nếu giá trị của biến này tăng thì sẽ làm giảm giá trị của biến kia.).
- - Hệ số tương quan có giá trị dương cho thấy mối quan hệ đồng biến hoặc tương quan dương (đồng biến tuyệt đối khi giá trị bằng 1)
- - Tương quan bằng 0 cho hai biến độc lập với nhau.





Kỹ thuật phát hiện các thuộc tính dư thừa



4 Tổng hợp dữ liệu



Kỹ thuật phát hiện các thuộc tính dư thừa



Pearson Correlation coefficient

- Hệ số tương quan Pearson được kí hiệu r . Dùng để đo lường mức độ tương quan tuyến tính giữa hai biến.
- Về nguyên tắc, tương quan Pearson sẽ tìm ra một đường thẳng phù hợp nhất với mối quan hệ tuyến tính của 2 biến.
- Hệ số tương quan Pearson sẽ nhận giá trị từ +1 đến -1

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$



Kỹ thuật phát hiện các thuộc tính dư thừa

Kiểm tra chi bình phương (Chi-Square test)



- Được sử dụng khi chúng ta muốn đánh giá xem liệu có mối quan hệ giữa hai biến trong một tập dữ liệu hay không.
- Nhằm trả lời câu hỏi: Hai biến có độc lập hay không?
- Phương pháp này thường được áp dụng:
 - Phương pháp lấy mẫu là lấy mẫu ngẫu nhiên đơn giản.
 - Các biến được nghiên cứu là dạng phân loại (categorical) hoặc định tính.

$$\chi^2 = \sum_i \frac{(O-E)^2}{E}$$

O = mỗi giá trị quan sát (thực tế)
E = mỗi giá trị kỳ vọng



Kỹ thuật phát hiện các thuộc tính dư thừa

Ví dụ:

Một cuộc thăm dò về giới tính có ảnh hưởng đến bằng cấp hay không.

Thực hiện một mẫu ngẫu nhiên đơn giản gồm 100 người.

Kết quả được hiển thị trong bảng dưới đây.



Bảng thống bằng cấp và giới tính				
	Cao Đẳng	ĐH	Sau ĐH	Tổng hàng
Nam	6	35	15	56
Nữ	4	34	6	44
Tổng cột	10	69	21	100

Tổng hợp dữ liệu



Kỹ thuật phát hiện các thuộc tính dư thừa

Cách tính như sau:



		BANGCAP			
		Cao dang	Dai hoc	Sau dai hoc	Xac Suat
GIOITINH	Nam	6	35	15	56%
	Nu	4	34	6	44%
Total	Xac Suat	10%	69%	21%	100%

$$\text{Xác suất} = (6 + 4) / 100$$

		BANGCAP			
		Cao dang	Dai hoc	Sau dai hoc	Xac Suat
GIOITINH	Nam	5.6	38.64	11.76	56%
	Nu	4.4	30.36	9.24	44%
Total	Xac Suat	10%	69%	21%	

$$\text{Số kỳ vọng} = 10\% \times 56\% \times 100$$

$$\begin{aligned} \text{Chi-square} &= (6-5.6)*(6-5.6)/5.6 + (35-38.64)*(35-38.64)/38.64 + (15-11.76)*(15-11.76)/11.76 \\ &+ (4-4.4)*(4-4.4)/4.4 + (34-30.36)*(34-30.36)/30.36 + (6-9.24)*(6-9.24)/9.24 = \mathbf{2.873} \end{aligned}$$



- Biến đổi dữ liệu là quá trình chuyển đổi định dạng, cấu trúc hoặc giá trị của dữ liệu.
- Thông thường được quá trình này được thực hiện trong giai đoạn ETL trong data warehouse.
- Biến đổi dữ liệu có thể bao gồm các công việc: tạo (thêm, sao chép và sao chép dữ liệu), xóa (xóa trường và bản ghi) hoặc thay đổi cấu trúc (đổi tên, di chuyển và kết hợp các cột trong cơ sở dữ liệu).

5 Biến đổi dữ liệu



Một vài phương pháp biến đổi dữ liệu

- Làm mịn: loại bỏ dữ liệu nhiễu.
- Tổng hợp: Tổng hợp dữ liệu từ nhiều nguồn khác nhau
- Chuẩn hóa: Chia dữ liệu thành một tỷ lệ nhỏ hoặc tỷ lệ nào đó.
- Xây dựng thuộc tính: Lựa chọn thuộc tính hoặc xây dựng thuộc tính mới từ các thuộc tính có được.



Một vài phương pháp biến đổi dữ liệu

1. Chuẩn hóa Min-max

Old values: $v \in [\min A, \max A]$

New values: $v' \in [\text{new_min}A, \text{new_max}A]$

$$v' = \frac{v - \min A}{\max A - \min A}$$



2. Chuẩn hóa z-score

Old values: v là trung bình $\bar{A}$, độ lệch chuẩn σ_A

New values: v'

$$v' = \frac{v - \bar{A}}{\sigma_A}$$

3. Chuẩn hóa theo tỷ lệ thập phân

Old values: v

New values: v' , trong đó j là giá trị nhỏ nhất

$$\text{Max}(|v'|) < 1$$

$$v' = \frac{v}{10^j}$$

1. Giới thiệu tiền xử lý dữ liệu
2. Công việc trong tiền xử lý dữ liệu
3. Làm sạch dữ liệu
4. Các cách làm sạch dữ liệu
5. Tổng hợp và biến đổi dữ liệu