



PHÂN TÍCH DỮ LIỆU

Chương 1

TỔNG QUAN VỀ PHÂN TÍCH DỮ LIỆU





1. Khái niệm về dữ liệu
2. Phân tích dữ liệu
3. Thời cơ và thách thức của chuyên ngành phân tích dữ liệu
4. Các lĩnh vực liên quan (AI, ML, Big Data)
5. Quá trình phân tích dữ liệu

1 Khái niệm về dữ liệu



Dữ liệu là gì?



1 Khái niệm về dữ liệu

Dữ liệu có cấu trúc và phi cấu trúc

- Dữ liệu lưu dưới dạng CSDL bảng
- Dữ liệu từ các nguồn khác nhau: hình ảnh, âm thanh, văn bản, tín hiệu.....

	allocation_unit_id	type	type_desc	container_id	data_space_id	total_pages	used_pages	data_pages
02	844424932894480	1	IN_ROW_DATA	844424932894480	1	0	0	0
03	844424933408760	1	IN_ROW_DATA	844424933408760	1	2	2	1
04	844424935760064	1	IN_ROW_DATA	844424935760064	1	0	0	0
85	1125899909070	1	IN_ROW_DATA	1125899909070	1	17	10	8
86	717761190514	2	LOB_DATA	281474500642816	1	12	6	0
87	7205759403799	1	IN_ROW_DATA	281474980511744	1	2	2	1
88	7205759403905	1	IN_ROW_DATA	562949957222400	1	2	2	1
89	7205759403819	1	IN_ROW_DATA	281474983067648	1	2	2	1



1 Khái niệm về dữ liệu



Các loại dữ liệu

Dữ liệu định tính (qualitative)

- Thang đo danh nghĩa, thang đo thứ bậc
- Loại dữ liệu này phản ánh tính chất, sự hơn kém
- Không tính toán được
- Ví dụ : giới tính: nam hay nữ; giỏi, khá, trung bình, yếu...

Dữ liệu định lượng (quantitative)

- Thang đo khoảng cách, thang đo tỉ lệ.
- Loại dữ liệu này phản ánh mức độ, sự hơn kém.
- Tính toán được.
- Thể hiện bằng con số, các con số này có thể ở dạng liên tục hay rời rạc.
- Ví dụ: độ tuổi, điểm số

1 Khái niệm về dữ liệu

Tập dữ liệu (dataset)

- Một tập dữ liệu (dataset) là một tập hợp các đối tượng (objects) và các thuộc tính của chúng.
- Mỗi thuộc tính (attribute or feature) mô tả một đặc điểm của một đối tượng.
- Ví dụ: Các thuộc tính *Refund*, *Marital Status*, *Taxable Income*, *Cheat*
- Một tập các giá trị của các thuộc tính mô tả một đối tượng.
- Đối tượng có tên gọi khác: bản ghi (record), điểm dữ liệu (data point), trường hợp (case), mẫu (sample), thực thể (entity), quan sát (observation)

Các thuộc tính

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Các đối tượng

1 Khái niệm về dữ liệu

Bản ghi (Record)

Các bản ghi trong csdl quan hệ.
Ma trận dữ liệu
Biểu diễn văn bản
Dữ liệu giao dịch.

	team	coach	play	ball	score	game	win	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0

Đồ thị (Graph)

World Wide Web
Mạng thông tin hoặc mạng xã hội.

Có trật tự (Ordered)

Dữ liệu không gian (VD: bản đồ)
Dữ liệu thời gian (VD: Time-series)
Dữ liệu chuỗi (VD: Chuỗi giao dịch)
Dữ liệu chuỗi di truyền (VD: chuỗi di truyền GEN)


<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

1

Khái niệm về dữ liệu



Hình 1



Hình 3



Hình 2



	A	B	C	D	E	F	G	H	I	J
1	wkt_geonid	Space (m)	Training	L/W	Head (m)	Shape	Slomea (%)	Slomax (%)	Region	
2	Point (14.1	1	2.88 VS	1.51	7 R	5.439745905	11.7355814	Abruzzo		
3	Point (13.7	2	1.56 VS	4.06	2.12 I	7.802203496	11.7355814	Abruzzo		
4	Point (13.5	3	2.33 VS	0.45	3.18 R	4.997994215	11.92272091	Abruzzo		
5	Point (14.1	4	2.66 VS	4.11	7 R	21.53995514	33.78640366	Abruzzo		
6	Point (13.5	5	2.28 VS	1.94	3.86 R	9.064147744	15.05548477	Abruzzo		
7	Point (14.0	6	1.88 VS	0.54	8.76 R	8.748559377	19.90818977	Abruzzo		
8	Point (13.7	7	2.18 VS	1.53	6.52 R	7.704525427	18.26987267	Abruzzo		
9	Point (13.8	8	3.25 VS	4.23	5.82 R	14.49181604	18.94792175	Abruzzo		

1 Khái niệm về dữ liệu

Các kiểu giá trị của thuộc tính

Kiểu định danh/chuỗi (nominal): không có thứ tự

Lấy giá trị từ một tập không có thứ tự các giá trị (định danh)

Vd: Các thuộc tính như: Name, Profession,...

Kiểu nhị phân (binary):

Đây là một trường hợp đặc biệt của kiểu định danh

Tập các giá trị chỉ gồm có 2 giá trị (Y/N, 0/1, T/F)

Kiểu có thứ tự (ordinal):

Lấy giá trị từ một tập có thứ tự các giá trị

Vd1: Các thuộc tính lấy giá trị số như: Age, Height,...

Vd2: Thuộc tính Income lấy giá trị từ tập {low, medium, high}

1 Khái niệm về dữ liệu

Các kiểu giá trị của thuộc tính

Kiểu thuộc tính rời rạc (Discrete-valued attributes)

Tập các giá trị là một tập hữu hạn.

Bao gồm cả các thuộc tính có kiểu giá trị là các số nguyên.

Bao gồm cả các thuộc tính nhị phân (binary attributes).

Kiểu thuộc tính liên tục (Continuous-valued attributes)

Các giá trị là các số thực (real numbers).

VD: Lương, tuổi, chiều cao, cân nặng.

height(cm)	weight(kg)
180	73
226	129
176	70
168	60
174	65
170	59
188	78

AGE	AGE_bins	
10	[10, 16]	80
15	[10, 16]	
16	[10, 16]	75
18	[17, 30]	
20	[17, 30]	
30	[17, 30]	
35	[31, 48]	
42	[31, 48]	
48	[31, 48]	
50	[49, 55]	
52	[49, 55]	
55	[49, 55]	

1 Khái niệm về dữ liệu



Dữ liệu là nguồn tài nguyên



1 Khái niệm về dữ liệu

Tại sao cần phải khai phá dữ liệu

- Sự bùng nổ của dữ liệu từ terabytes tới petabytes, exabytes, zettabytes, yottabytes.
 - Ví dụ: máy bay Boeing thế hệ mới (84TB cho 12h bay), dữ liệu upload của Youtube hàng ngày (24 PB/ngày)
- Một số nguồn dữ liệu đa dạng
 - Các nguồn thu thập dữ liệu, CSDL, Web Kinh doanh: Web, thương mại điện tử, giao dịch, chứng khoán, tài chính...
 - Khoa học: thông tin viễn thám, tin sinh học, giả lập khoa học, ...
 - Mạng xã hội và con người: tin tức, cameras, YouTube, IG, TikTok, Facebook...
- Chúng ta bị tràn ngập trong dữ liệu nhưng thiếu thông tin cung cấp từ nó
- **Cần thiết ra đời công cụ/giải pháp để hiểu về dữ liệu: Data Mining, phân tích dữ liệu**

1 Khái niệm về dữ liệu



Tiến triển của khoa học

- Trước 1600 : khoa học theo chủ nghĩa kinh nghiệm
- 1600-1950s, **khoa học lý thuyết**
 - Mỗi chuyên ngành phát triển một lý thuyết riêng. Các mô hình lý thuyết dẫn đến thực nghiệm để hiểu rõ vấn đề
- 1950s-1990s, **khoa học tính toán**
 - Hơn 50 năm phát triển, các chuyên ngành đều phát triển hướng tính toán (môi trường, vật lý, hóa học, ngôn ngữ..)
 - Đòi hỏi môi trường giả lập và các công cụ toán học phức

1 Khái niệm về dữ liệu



Tiến triển của khoa học

- 1990-nay, **khoa học dữ liệu**
 - Tràn ngập về dữ liệu từ các công cụ khoa học mới được phát minh (cảm biến sensors và các bộ giả lập)
 - Khả năng lưu trữ dữ liệu lớn.
 - Internet và mạng lưới tính toán đã giúp tiếp cận nguồn dữ liệu này một cách dễ dàng.
 - Thông tin khoa học, quản lý, thu thập, truy vấn, biểu diễn và quan sát nguồn dữ liệu lớn này là một thách thức đối với chuyên ngành Khai phá dữ liệu, phân tích dữ liệu.
- **Công nghiệp 4.0**

1 Khái niệm về dữ liệu

Tiến triển của công nghệ CSDL

- 1960s: Thu thập và tạo dữ liệu
- 1970s: Mô hình dữ liệu quan hệ DBMS
- 1980s: Mô hình dữ liệu tiên tiến RDBMS và các ứng dụng liên quan.
- 1990s: Khai phá dữ liệu, nhà kho dữ liệu, dữ liệu đa phương tiện.
- 2000s
 - Quản lý và streaming dữ liệu.
 - Khai phá dữ liệu và ứng dụng.
 - Công nghệ Web (XML, data integration), GIS.



1. Giới thiệu phân tích dữ liệu
2. Các kỹ năng cần để phân tích dữ liệu
3. Các loại phân tích dữ liệu




Khái niệm phân tích dữ liệu

Data Analysis is one aspect of Data Science which is all about analysing data for different kinds of purposes.

Data Scientist

Data scientists examine which questions need answering and where to find the related data. They have business acumen and analytical skills as well as the ability to mine, clean, and present data. Businesses use data scientists to source, manage, and analyze large amounts of unstructured data.



Berkeley School of Information



Khái niệm phân tích dữ liệu

Data Analysis is one aspect of Data Science which is all about analysing data for different kinds of purposes.

Data Analyst

Data analysts bridge the gap between **data scientists** and **business analysts**. They are provided with the questions that need answering from an organization and then organize and analyze data to find results that align with high-level business strategy.

Data analysts are responsible for translating technical analysis to qualitative action items and effectively communicating their findings to diverse stakeholders.





Khái niệm phân tích dữ liệu



Phân tích dữ liệu được định nghĩa là môn khoa học phân tích các dữ liệu “thô” (raw data) để đi đến những kết luận hoặc đưa ra các quyết định. Bằng cách thu thập, chọn lọc và tìm kiếm những thông tin quan trọng từ tất cả thông tin, dữ liệu có được.

Phân tích dữ liệu là một quá trình kiểm tra, phân tích, chuyển đổi và mô hình hóa dữ liệu với mục tiêu tìm hiểu, làm rõ thông tin hữu ích để đưa ra kết luận và hỗ trợ việc đưa ra quyết định.




Khái niệm phân tích dữ liệu



Phân tích dữ liệu là quá trình làm việc với dữ liệu để thu thập các thông tin hữu ích, từ đó sử dụng kết quả phân tích để đưa ra các quyết định liên quan đến các kế hoạch chiến lược của công ty.

Phân tích dữ liệu là quá trình thu thập, mô hình hóa và phân tích dữ liệu để rút ra những hiểu biết sâu sắc hỗ trợ việc ra quyết định.

Lợi ích của phân tích dữ liệu



- Tăng hiệu quả công việc
- Hỗ trợ ra quyết định
- Dự đoán những hành vi của khách hàng
- Cá nhân hóa trải nghiệm khách hàng
- Cải tiến sản phẩm/dịch vụ

2 Phân tích dữ liệu



Lợi ích của phân tích dữ liệu



- Nhắm mục tiêu chính xác hơn
- Tìm ra Insight khách hàng
- Đưa ra các quyết định kinh doanh
- Hiểu rõ thị trường kinh doanh
- Xây dựng chiến lược digital marketing
- Hỗ trợ, tăng năng suất làm việc của nhân viên
- Theo dõi đối thủ cạnh tranh.

Các kỹ năng phân tích dữ liệu




- Kỹ năng phân tích
- Kỹ năng thống kê
- Kỹ năng lập trình
- Tư duy phản biện
- Kiến thức về Machine Learning, Deep Learning và AI
- Có kiến thức về Python, R, SAS và Scala
- Kỹ năng thuyết trình
- Kỹ năng tiền xử lý dữ liệu
- Trực quan hóa dữ liệu
- Khả năng làm việc với dữ liệu phi cấu trúc



1. Data Visualization
2. Data Cleaning
3. MATLAB
4. R
5. Python
6. SQL and NoSQL
7. Machine Learning
8. Linear Algebra and Calculus
9. Microsoft Excel
10. Critical Thinking
11. Communication





1. Structured Query Language (SQL)
2. NoSQL
3. Business intelligence tools
4. Python
5. R
6. Statistics
7. Writing and communication
8. Problem solving and critical thinking



2 Phân tích dữ liệu



Các loại phân tích dữ liệu

Thống kê là nền tảng của phân tích dữ liệu

- Thống kê mô tả
- Thống kê suy luận



Các loại phân tích dữ liệu

Thống kê mô tả (Descriptive Statistics) là các phương pháp sử dụng để tóm tắt hoặc mô tả một tập hợp dữ liệu, một mẫu nghiên cứu dưới dạng số hay biểu đồ trực quan.

Các công cụ trực quan thường dùng nhất là các biểu đồ.

Các công cụ số dùng để mô tả thường dùng nhất:

- Các đại lượng về trung tâm
- Các đại lượng về độ phân tán
- Các đại lượng về hình dáng phân phối
- Các đại lượng về sự tương quan





Các loại phân tích dữ liệu

Thống kê suy luận (inferential statistics) là quá trình suy ra các đặc điểm của một phân phối cơ bản. Mục tiêu là rút ra kết luận từ một mẫu và khái quát hóa chúng thành một quần thể.

Bao gồm các phương pháp ước lượng các đặc trưng của tổng thể, phân tích mối liên hệ giữa các hiện tượng nghiên cứu, dự đoán hoặc ra quyết định.

- Kiểm định giả thuyết
- Phân tích hồi quy
- Học máy



2 Phân tích dữ liệu



Các loại phân tích dữ liệu



DESCRIPTIVE ANALYTICS
historical data in an organized form

Phân tích mô tả



DIAGNOSTIC ANALYTICS
"Why did X happen to Y data?"

Phân tích chẩn đoán



PREDICTIVE ANALYTICS
predictions about likely outcomes in the near future

Phân tích dự đoán



PRESCRIPTIVE ANALYTICS
suggestions about what to do next, given the information from predictive analytics

Phân tích đề xuất

Các loại phân tích dữ liệu



- Phương pháp phân tích mô tả là điểm khởi đầu cho bất kỳ quá trình phân tích nào.
- Phân tích mô tả cho chúng ta **biết điều gì đã xảy ra**.
- Loại phân tích này giúp mô tả hoặc tóm tắt dữ liệu định lượng bằng cách trình bày các số liệu thống kê.
- Phổ biến nhất của phân tích mô tả là các loại báo cáo tài chính, báo cáo doanh thu, tình hình kinh doanh của công ty,
- Ví dụ: giá qua từng năm, tăng trưởng doanh số hàng tháng, số lượng người dùng hoặc tổng doanh thu trên mỗi người đăng ký.

Các loại phân tích dữ liệu



- Một trong những loại hình phân tích dữ liệu mạnh mẽ nhất.
- Phương pháp nhằm để xác định: **Tại sao điều này lại xảy ra?**
- Phân tích chuẩn đoán tìm hiểu sâu vào dữ liệu để tìm kiếm thông tin chi tiết có giá trị.
- Phân tích chẩn đoán thường được thực hiện bằng cách sử dụng các kỹ thuật như Exploratory analysis (khám phá dữ liệu), drill-down (xem chi tiết), data mining (khai thác dữ liệu) và correlations (các mối tương quan).

2 Phân tích dữ liệu



Các loại phân tích dữ liệu



- Phương pháp dựa vào dữ liệu để trả lời câu hỏi: điều gì sẽ xảy ra trong tương lai?
- Để làm được điều này, phương pháp phân tích dự đoán sử dụng kết quả của phân tích mô tả, khám phá và chẩn đoán đã đề cập trước đó.
- Sử dụng các phương pháp hiện đại: Data mining, học máy (Machine Learning) và trí tuệ nhân tạo (Artificial Intelligent).

Các loại phân tích dữ liệu



- Một trong những loại phương pháp phân tích dữ liệu hiệu quả nhất trong nghiên cứu.
- Phân tích đề xuất nhằm trả lời cho câu hỏi: **Nó sẽ diễn ra như thế nào?**
- Phân tích đề xuất sử dụng kết quả của phân tích mô tả, phân tích chẩn đoán và phân tích dự đoán để đề xuất phương án giải quyết tốt nhất.
- Sử dụng các phương pháp phân tích dự đoán hiện đại như: Machine learning, AI



THE FOUR MAIN TYPES OF DATA ANALYSIS

Descriptive

What happened?

Diagnostic


Why did it happen?

Predictive

What is likely to happen in the future?

Prescriptive

What's the best course of action?



OCT
2021

SOCIAL MEDIA PLATFORMS: USER OVERLAPS

PERCENTAGE OF USERS AGED 16 TO 64* OF EACH SOCIAL MEDIA PLATFORM (OUTSIDE OF CHINA) WHO ALSO USE OTHER SOCIAL MEDIA PLATFORMS

⚠ THE QUESTIONS THAT INFORM THIS CHART HAVE CHANGED, SO VALUES ARE NOT COMPARABLE WITH THOSE PUBLISHED IN PREVIOUS REPORTS

	UNIQUE TO PLATFORM	ALSO USING FACEBOOK	ALSO USING YOUTUBE	ALSO USING INSTAGRAM	ALSO USING REDDIT	ALSO USING SNAPCHAT	ALSO USING TWITTER	ALSO USING TIKTOK	ALSO USING PINTEREST	ALSO USING LINKEDIN
FACEBOOK USERS	0.7%	100.0%	75.2%	77.6%	13.8%	32.2%	49.2%	44.9%	36.6%	31.9%
YOUTUBE USERS	1.0%	79.9%	100.0%	77.8%	15.3%	29.9%	52.1%	42.6%	38.6%	31.9%
INSTAGRAM USERS	0.1%	83.1%	78.8%	100.0%	14.9%	36.7%	55.0%	47.8%	40.7%	31.9%
REDDIT USERS	0.1%	81.4%	79.2%	82.5%	100.0%	50.0%	73.0%	51.4%	59.4%	50.1%
SNAPCHAT USERS	0.1%	83.7%	79.2%	88.9%	21.9%	100.0%	62.8%	58.4%	51.0%	38.9%
TWITTER USERS	0.2%	83.8%	80.9%	87.5%	21.0%	41.2%	100.0%	51.9%	44.6%	40.2%
TIKTOK USERS	0.1%	85.0%	81.3%	84.4%	16.4%	42.6%	57.7%	100.0%	44.4%	31.7%
PINTEREST USERS	0.1%	83.0%	80.5%	86.3%	22.7%	44.5%	59.5%	53.2%	100.0%	42.2%
LINKEDIN USERS	0.3%	88.4%	78.3%	82.5%	23.4%	41.6%	65.4%	46.5%	51.5%	100.0%





Cơ hội rất lớn đối với ngành phân tích dữ liệu

- **Ngành tài chính – ngân hàng:** Phát hiện rủi ro và hoạt động gian lận.
- **Ngành y tế, chăm sóc sức khỏe:** Hỗ trợ bác sĩ chuẩn đoán bệnh, đánh giá các triệu chứng, dự đoán các chứng bệnh nguy hiểm, dự đoán các khu vực/thời điểm bùng dịch nguy hiểm.
- **Ngành thương mại điện tử:** Phân tích thị hiếu thị trường, tự động hóa và cá nhân hóa đề xuất.
- **Ngành Marketing:** tự động hóa và cá nhân hóa các hoạt động digital marketing.
- **Ngành giáo dục:** Xác định nhu cầu nhân sự, định hướng tuyển sinh đào tạo.



How Safe Is Your Password?

Time it would take a computer to crack a password with the following parameters

	Number of characters			
	Lowercase letters only	At least one lowercase letter	At least one uppercase letter +number	At least one uppercase letter +number+symbol
1	Instantly	Instantly	-	-
2	Instantly	Instantly	Instantly	-
3	Instantly	Instantly	Instantly	Instantly
4	Instantly	Instantly	Instantly	Instantly
5	Instantly	Instantly	Instantly	Instantly
6	Instantly	Instantly	Instantly	Instantly
7	Instantly	Instantly	1 min	6 min
8	Instantly	22 min	1 hrs	8 hrs
9	2 min	19 hrs	3 days	3 wks
10	1 hrs	1 mths	7 mths	5 yrs
11	1 day	5 yrs	41 yrs	400 yrs
12	3 wks	300 yrs	2,000 yrs	34,000 yrs

Source: Security.org



Big Data Analytics





- Khối lượng (Volume)
- Tốc độ (Velocity): Tốc độ thay đổi của dữ liệu
- Đa dạng (Variety): Đa dạng nguồn dữ liệu (kiểu dữ liệu, tính chất của dữ liệu)
- Tính xác thực (Veracity)
- Giá trị (Value)

Bên cạnh nhiều cơ hội thì ngành phân tích dữ liệu còn đối mặt với nhiều thách thức như: khối lượng dữ liệu lớn, tốc độ xử lý, độ chính xác, chi phí lưu trữ...

Khai phá dữ liệu là gì?

- Khai phá dữ liệu: tìm kiếm thông tin và kiến thức từ nguồn dữ liệu
 - Truy xuất mẫu hoặc kiến thức quan trọng (non-trivial, implicit, previously unknown and potentially useful) từ nguồn dữ liệu lớn
- Tên gọi khác
 - Knowledge discovery (mining) in databases (KDD), knowledge extraction, data/pattern analysis, data archeology, data dredging, information harvesting, business intelligence, etc.





Data mining đóng vai trò quan trọng trong việc khám phá kiến thức (thông tin) từ nguồn dữ liệu.



Quá trình data mining có thể gồm các bước sau

- Data cleaning
- Data integration from multiple sources
- Warehousing the data
- Data selection for data mining
- Data mining
- Presentation of the mining results
- Patterns and knowledge to be used or stored into knowledge-base



The Difference Between Data Science, AI, and ML



DATA SCIENCE

The practice of organizing and analyzing data to gain insights that may prove helpful for human decision-making.

- Data science draws on **multiple fields** that include statistics, mathematics, and computer science.
- Artificial intelligence (specifically machine learning) has become an **important tool** for data scientists.



ARTIFICIAL INTELLIGENCE (AI)

A concept referring to how computers and machines can demonstrate intelligent behavior.

- AI possesses **intelligent behaviors**, learning capabilities, and self-awareness on a human level. Still science fiction!
- Narrow AI refers to existing such systems that focus on **learning and performing** specific tasks.




MACHINE LEARNING (ML)

A subcategory of AI that enables computer algorithms to automatically learn from data.


- ML is the **most common form of AI** in real-world applications such as image recognition and natural language processing.
- ML **automates the process** of analyzing big data, allowing data scientists to focus on deriving useful insights.

Phân loại ngữ cảnh đối với Machine Learning







Semi-supervised

Các quá trình trong Machine Learning




Ví dụ về bài toán Machine Learning




Bài toán phân cụm


Cluster 1



Cluster 2




Cluster 3





Bài toán phân loại/Phân lớp




Poodle



Corgi




Husky




4 Các lĩnh vực liên quan


Ví dụ khác về việc nhận dạng (classification)




KDD dưới góc nhìn của Machine Learning và Statistics



KDD - Knowledge Discovery in Databases



Sự giao thoa giữa các ngành với nhau





Tại sao lại cần kiến thức đa ngành?

- Lượng dữ liệu lớn: thuật toán để xử lý lượng dữ liệu hàng TB
- Kích thước lớn: dữ liệu DNA, tài chính, kinh doanh
- Độ phức tạp
 - Dữ liệu từ các sensors
 - Dữ liệu chuỗi thời gian: thời tiết, ECG
 - Dữ liệu có cấu trúc, liên kết: mạng xã hội, đồ thị
 - Multimedia data: ảnh, video, text,...
 - Phần mềm, mô phỏng khoa học
- Các ứng dụng mới liên tục được phát triển



Một vài ứng dụng của lĩnh vực data mining

- Phân tích Web: phân loại, gom cụm, xếp hạng
- Hệ thống gợi ý
- Phân tích dữ liệu tài chính, marketing
- Phân tích dữ liệu y sinh: phân loại protein, phân tích gene, phylogeny...
- Thị giác máy tính, Nhận dạng mẫu, nhận dạng sinh trắc học
- Xử lý dữ liệu : trích xuất và rút gọn đặc trưng.
- Classification hoặc/và clustering
- Xử lý để biểu diễn dữ liệu

5 Quá trình phân tích dữ liệu



Ask

Ask questions and define the problem.



Prepare

Prepare data by collecting and storing the information.



Process

Process data by cleaning and checking the information.



Analyze

Analyze data to find patterns, relationships, and trends.



Share

Share data with your audience.



Act

Act on the data and use the analysis results.



THE DATA ANALYSIS PROCESS

Step 1:

Define the question

Step 2:

Collect the data

Step 3:



Clean the data


Step 4:

Analyze the data

Step 5:

Visualize and share your findings







Predictive Analytics Lifecycle

1. Problem Definition
2. Data Exploration
3. Data Selection & Preparation
4. Model Training & Validation
5. Model Evaluation & Deployment
6. Monitoring & Performance Analytics
7. Maintenance, Fine-tuning update

5 Quá trình phân tích dữ liệu





What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

Tổng kết



Chúng ta đã tìm hiểu qua các khái niệm

1. Khái niệm về dữ liệu
2. Phân tích dữ liệu: các loại phân tích, kỹ năng
3. Thời cơ và thách thức của chuyên ngành phân tích dữ liệu
4. Các lĩnh vực liên quan (AI, ML, Big Data)
5. Quá trình phân tích dữ liệu